

ESTUDO DE CASO: QUITANDA MAXVITA

A quitanda MAXVITA deseja automatizar a classificação de frutas para agilizar o processo de separação em caixas de distribuição. O proprietário identificou que a diferenciação entre maçãs e laranjas pode ser realizada a partir de duas características facilmente mensuráveis: peso da fruta (em gramas) e textura da casca (0 para lisa e 1 para rugosa). Para isso, foi contratada uma equipe de desenvolvedores que decidiu utilizar uma rede neural Perceptron de camada única como solução computacional. A tabela a seguir apresenta exemplos de frutas já classificadas:

Peso (g)	Textura (0 = lisa e 1 = rugosa)	Classe esperada
150	0	Maçã
170	0	Maça
140	1	Laranja
180	1	Laranja

O Perceptron proposto deve receber dois valores de entrada (peso e textura) e gerar uma saída binária: 0 para representar “Maçã” e 1 para representar “Laranja”. O processo de aprendizagem ocorre pela atualização dos pesos do modelo de acordo com o erro entre a saída prevista e a saída esperada.

ATIVIDADES A SEREM REALIZADAS:

- 1- Implementar a rede neural Perceptron na linguagem Python. Essa implementação deve ser realizada sem a utilização de bibliotecas e/ou frameworks externos.
- 2- O modelo de rede neural a ser utilizado deve possuir a seguinte arquitetura: 1 camada de entrada com 2 neurônios (peso e textura) e 1 camada de saída com 1 neurônio que representa a classe fruta (Maçã ou Laranja). A função de ativação a ser utilizada é a Degrau (Step Function) e a taxa de aprendizado a ser definida deve ser 0.01.

3- A base de dados original será composta por 30 exemplos, sendo destes 21 exemplos para treinamento e 9 exemplos para teste. A base de dados de treinamento e teste estão disponíveis na ferramenta Teams, no seguinte formato:

- Coluna 1: Peso (g)
- Coluna 2: Textura (0 = lisa, 1 = rugosa)
- Coluna 3: Classe (0 = maçã, 1 = laranja)

4 – O treinamento do modelo deverá ser realizado conforme o procedimento descrito a seguir:

- Inicialização dos pesos e bias em valores pequenos (zero ou aleatórios).
- Execução de épocas de treinamento sobre a base de dados.
- Atualização dos pesos segundo a fórmula:

$$\begin{aligned}w_i &\leftarrow w_i + \eta \cdot (y_{esperado} - y_{previsto}) \cdot x_i \\b &\leftarrow b + \eta \cdot (y_{esperado} - y_{previsto})\end{aligned}$$

- Critério de parada: Número máximo de épocas ou erro mínimo.

5 – A etapa de testes e avaliação deve utilizar como métrica a acurácia (n° de acertos / n° de exemplos) $\times 100$. Como resultados obtidos, nós temos: os pesos finais obtidos após o treinamento, exemplo de classificação de uma fruta nova e avaliação de desempenho (quantos exemplos foram classificados corretamente).